

DETECTIA LEGUMELOR BOLNAVE

ECHIPA: CROP
GUARDIANS

INTRODUCERE

Agricultura modernă se confruntă cu:

- schimbări climatice,
- creșterea populației,
- nevoia de securitate alimentară.

Bolile plantelor afectează sever culturile – fiind necesară detectarea timpurie.

Metodele tradiționale:

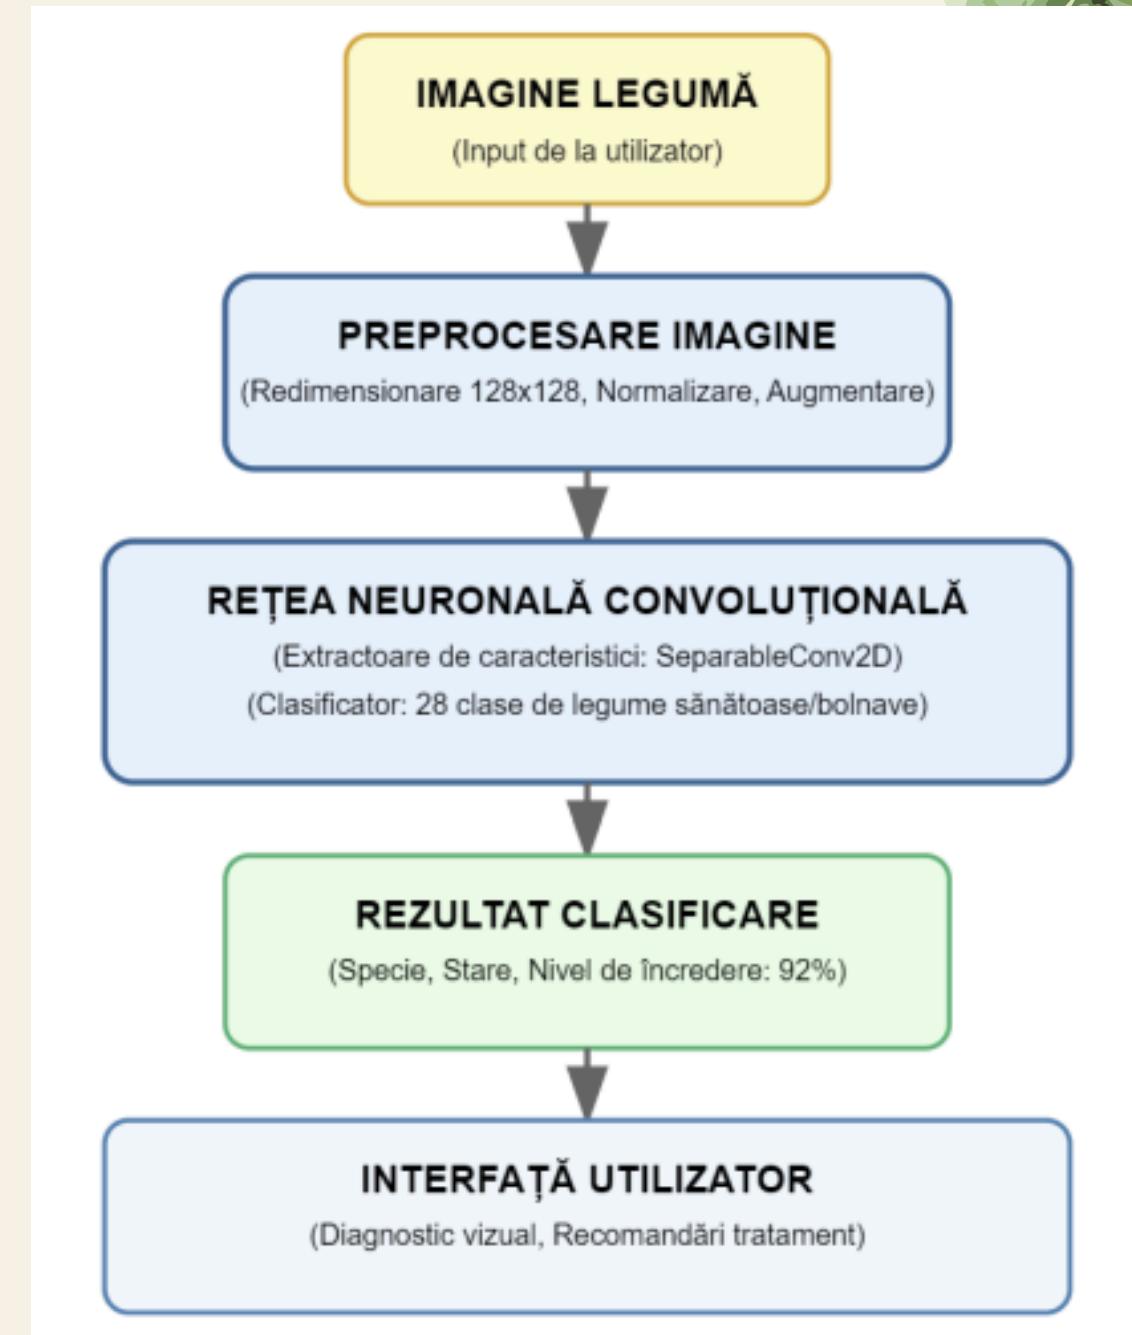
- se bazează pe inspectarea vizuală de experți,
- sunt costisitoare și predispuse la erori.

Numărul redus de specialiști face monitorizarea dificilă și ineficientă.

Astfel, am pornit de la o problemă actuală a agriculturii moderne: detectarea târzie a bolilor duce la pierderi uriașe. Soluțiile clasice sunt lente, costisitoare și depind de specialiști greu de găsit.

DE CE AI? AVANTAJELE ABORDĂRII NOASTRE

- Detectare precisă a simptomelor subtile → mai bună decât ochiul uman.
- Scalabilitate: modelul poate analiza mii de imagini rapid.
- Accesibilitate: integrare în aplicație mobilă, utilizabilă direct în câmp.
- Detectare timpurie → prevenirea răspândirii bolii.
- Modelul se poate îmbunătăți continuu cu noi date.
- Reducerea pesticidelor → tratamente aplicate doar unde e necesar.



RELATED WORK

“Disease Detection in Vegetables Using Image Processing Techniques” (2021)

- Date: imagini RGB din camere/smartphone-uri, uneori multispectrale
- Algoritmi: segmentare imagine, wavelet, ANN, SVM, CNN
- Rezultate:
 - CNN: 96% acuratețe la tomate
 - SVM și CNN: precizie >95%
 - YOLOv5 pe mobil: 93.1% (Li et al., 2022)

“YOLOv8 îmbunătățit pentru boli în sere” (2023)

- Date: 28.000 imagini extrase din video (20 boli, 3 legume)
- Algoritmi: YOLOv8n-vegetable cu GhostConv, OAM, strat obiecte mici
- Rezultate:
 - mAP: 92.91% ($\uparrow +6.46\%$ față de YOLOv8n)
 - Viteză: 271 FPS
 - Stabilitate >82% pe imagini needitate
 - Variante noi (MIFV): mAP 92.38%

METODE FOLOSITE IN PROIECT

Algoritmi utilizați:

- Model inițial CNN: straturi Conv2D + MaxPooling + Dense
- Model îmbunătățit CNN:
 - SeparableConv2D (mai eficient)
 - Skip connections (Add)
 - BatchNormalization
 - GlobalAveragePooling2D
 - Număr parametri: 26.124 (vs. 1.967.496 inițial)

Procesul de antrenare:

- Redimensionare imagini la 128×128 , normalizare [0,1]
- Split: 80% train / 20% test
- Optimizator: Adam, loss: categorical crossentropy
- Tehnici: dropout (0.5), batch variabil (64/128), antrenare incrementală

Metrici de evaluare:

- Accuracy, Precision, Recall, F1-Score, Loss
- Matrice de confuzie – evidențiază clasele confundate

REZULTATE OBȚINUTE

Model inițial:

- Accuracy: 65%
- Dimensiune model: 7.51 MB
- Probleme de overfitting
- Performanță slabă la clase rare
(Precision/Recall < 50%)

Model îmbunătățit:

- Accuracy: 92%
- Dimensiune model: 102 KB (\downarrow de 75x)
- Generalizare mai bună, chiar și pe clase cu puține exemple
- Precision și Recall ridicate pe majoritatea claselor

EFICIENTA

Eficientă computațională:

- Parametri: 1.9M → 26K
- Ideal pentru aplicații mobile sau offline

Matrice de confuzie:

- Modelul îmbunătățit are:
 - mai puține confuzii între clase similare
 - performanță uniformă între categorii

Modelul optimizat este mai precis, mai mic și mai rapid – fără a compromite acuratețea.

COMPARAȚIE CU LITERATURA DE SPECIALITATE

Rezultate din alte lucrări:

- Steinbrener et al. (2021): 91% accuracy
- Femling et al. (2018): 89% accuracy
- YOLOv5 (Li et al., 2022): 93.1% accuracy

Modelul nostru:

- 92% accuracy cu arhitectură personalizată și eficientă
- Dimensiune mult mai mică decât modelele din literatură
- Utilizează cele mai noi practici (SeparableConv, BatchNorm, SkipConn)

Fruit & Vegetables Classifier

Click to upload or drag an image



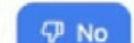
Fruit & Vegetables Classifier



Prediction:
Pomegranate Healthy

Confidence: 99.98%

Was the prediction correct?



CONCLUZII

Concluzii:

- Modelul CNN optimizat a atins 92% acuratețe pe 28 de clase.
- Dimensiunea modelului a fost redusă de 75x → potrivit pentru mobil.
- Interfață intuitivă → diagnostic rapid și recomandări utile pentru

Possible îmbunătățiri:

- Extinderea datasetului: mai multe specii, boli și condiții de iluminare.
- Transfer learning: testarea EfficientNet sau MobileNetV3.
- Funcționalitate offline + sistem de feedback pentru învățare continuă.
- Alertare și predicție a răspândirii bolilor pe baza condițiilor climatice.

VA MULTUMIM!

Q&A TIME